

# PACS 复现项目：GSE157079 UMAP 重建与 P56 批次效应去除阶段报告

阶段总结：数据接入、矩阵对齐、matrix-derived UMAP、P56 PACS batch peak filtering 与定量评估

## 1. 报告目的

本报告总结 PACS 复现项目中 “GSE157079 UMAP 重建与 P56 PACS batch-effect filtering” 阶段的主要进展。重点包括：GSE157079 数据接入、MatrixMarket 矩阵与 metadata/peak list 对齐、从原始 cell-by-peak matrix 重建 TF-IDF/LSI/UMAP、P56 子集 PACS batch peak removal、定量评估以及当前仍存在的问题。

本报告不是完整论文复现报告，而是 UMAP 任务阶段报告；Notebook 1 benchmark 复现已经作为前置阶段完成。

## 2. 数据与文件基础

GSE157079 数据由 metadata、UMAP coordinates、peak list 和 cell-by-peak MatrixMarket 矩阵支撑。当前已经确认这些文件可以对齐。

| 项目                | 当前确认结果                                                     |
|-------------------|------------------------------------------------------------|
| metadata 细胞数      | 28,316                                                     |
| peak list 峰数      | 300,755                                                    |
| MatrixMarket 维度   | 28,316 cells x 300,755 peaks                               |
| MatrixMarket 非零元素 | 166,121,193                                                |
| 矩阵方向              | cell x peak                                                |
| 合并 metadata 标准列   | row_index, cell_barcode, sample, cell_type, umap_1, umap_2 |

### 样本数量

| sample     | n     |
|------------|-------|
| P56_batch1 | 7,129 |
| P56_batch2 | 6,397 |
| P0_batch1  | 5,993 |
| P0_batch2  | 5,436 |
| P21_batch1 | 3,361 |

### 主要细胞类型

| cell type | n     |
|-----------|-------|
| PT        | 7,412 |
| LOH       | 3,628 |
| stroma2   | 3,539 |
| Endo      | 2,368 |
| NP        | 2,232 |
| PT2       | 1,943 |

数据接入阶段修复了两个关键问题：`data.table` 索引问题，以及 10x-style barcode 不应被要求全局唯一。UMAP 文件没有 barcode，因此 metadata 与 UMAP 使用 `row_index` 合并，同时用 `sample + cell_barcode` 做 sanity check。

## 3. 为什么不能直接使用 GEO 自带 UMAP

GEO 提供的 UMAP 对快速浏览数据很有用，但它只是预计算坐标。PACS 论文图更强调 all-feature / filtered-feature UMAP：先用大量 features 构建 UMAP，再用 PACS 检测并去除 batch-associated features 后重建 UMAP。因此，本项目没有把 GEO UMAP 当作最终复现目标，而是回到原始 cell-by-peak matrix，重建 matrix-derived TF-IDF/LSI/UMAP。




图 1. GEO 预计算 UMAP，按 sample 着色。用于概览，但不等同于 PACS paper-style UMAP。




图 2. GEO 预计算 UMAP，按 cell type 着色。

#### 4. 从原始矩阵重建 UMAP 的路线

当前路线为：流式读取 MatrixMarket `.gz` 文件，避免解压原始文件和 dense matrix materialization；计算 peak detection count 和 cell depth；选择 top detected peaks；构建 sparse cells x peaks matrix；二值化 counts；TF-IDF 标准化；`irlba` 计算 LSI；`uwot` 基于 LSI 2:30 重建 UMAP。

| 项目                 | 结果              |
|--------------------|-----------------|
| cells              | 28,316          |
| selected top peaks | 20,000          |
| retained nonzeros  | 85,801,336      |
| sparse matrix      | 28,316 x 20,000 |
| LSI                | 28,316 x 50     |
| UMAP 输入维度          | LSI 2:30        |




图 3. 从原始矩阵重建的 all-cell top-peak UMAP，按 sample 着色。




图 4. 从原始矩阵重建的 all-cell top-peak UMAP，按 cell type 着色。

该结果说明 matrix-derived TF-IDF/LSI/UMAP 流程已经跑通，并成为后续 “before PACS filtering” 的基础逻辑。

#### 5. 为什么先做 P56 子集

完整数据包含 P0、P21 和 P56。年龄/发育阶段差异本身是重要生物学信号，不能简单当作 batch effect 去除。因此当前先固定 P56，比较同一年龄下的两个 batch。

| batch      | n     |
|------------|-------|
| P56_batch1 | 7,129 |
| P56_batch2 | 6,397 |

P56 子集共有 13,526 个细胞。使用 `min_cells_per_celltype = 30` 和 `min_cells_per_batch_per_celltype = 5` 后没有细胞类型被移除。

#### 6. PACS batch-effect peak 检测模型

P56 分析中的 batch 定义为 `P56_batch1 vs P56_batch2`。PACS 模型为 `full model: ~ cell_type + batch`，`null model: ~ cell_type`。这表示在控制 cell type 后，检测每个 peak 是否仍存在 batch-associated accessibility effect。

原始 GSE157079 矩阵方向是 cells x peaks；PACS 输入方向是 peaks x cells。当前脚本显式转置并检查输入维度。由于 GSE157079 没有作者 Notebook 1 中的 `q_vec`，当前 `cap_rates` 使用 selected top peaks 的相对 cell depth 近似，并缩放至最大 0.99。

7. P56 主结果：10000/10000/FDR0.05

| 参数/结果                   | 值                             |
|-------------------------|-------------------------------|
| run_name                | p56_top10000_test10000_fdr005 |
| P56 sparse matrix       | 13,526 x 10,000               |
| nnz                     | 28,479,654                    |
| tested peaks            | 10,000                        |
| significant batch peaks | 6,305                         |
| retained peaks          | 3,695                         |
| after-filtering TF-IDF  | 13,526 x 3,695                |
| after-filtering LSI     | 13,526 x 50                   |




图 5. P56 PACS batch-effect peak filtering 主结果。去除 PACS-significant batch peaks 后，batch 着色的分离明显减弱，cell type 结构仍保留。

8. 定量评估：batch mixing 与 cell type preservation

| setting             | tested | sig batch | retained | after batch silhouette | after entropy | after same-batch | after batch acc | after celltype silhouette | after same-celltype |
|---------------------|--------|-----------|----------|------------------------|---------------|------------------|-----------------|---------------------------|---------------------|
| 5000/5000/FDR0.05   | 5,000  | 3,140     | 1,860    | 0.0266                 | 0.6956        | 0.6969           | 0.5899          | 0.1593                    | 0.6650              |
| 10000/10000/FDR0.05 | 10,000 | 6,305     | 3,695    | 0.0133                 | 0.7111        | 0.6810           | 0.5754          | 0.3020                    | 0.7759              |
| 20000/10000/FDR0.05 | 10,000 | 6,208     | 3,792    | 0.0139                 | 0.6878        | 0.7016           | 0.5320          | 0.3026                    | 0.7803              |

5000 设置可以降低 batch separation，但 cell type structure 损失较大。10000/10000 在 batch mixing 和 cell type preservation 之间最平衡。20000/10000 是稳定性检查：它支持 10000/10000 结果的稳健性，但没有明显优于主结果，因此暂时不替代主结果。




图 6. P56 10000/10000/FDR0.05 主结果的 batch mixing 与 cell type preservation 定量指标。

## 9. 推进过程中的主要思想

- 不把 GEO UMAP 当作最终复现目标，而是回到原始 cell-by-peak matrix。
- 先做 smoke test 验证 matrix、metadata 和 peak list 对齐。
- 先做小规模 pilot，再做 all-cell top-peak UMAP。
- 因为全数据包含年龄/发育差异，先固定 P56 做 batch filtering。
- PACS 检测时控制 cell type，避免把细胞类型结构误判为 batch effect。
- 同时使用 UMAP 可视化和 quantitative metrics，而不是只看图。
- 参数优化遵循“增加 tested peaks，暂不放宽 FDR”的策略，避免过度过滤。
- 10000/10000 作为主结果，20000/10000 作为稳定性验证。

## 10. 当前问题和局限

当前分析仍是 P56-only、top detected peaks only，并且 `cap_rates` 是基于 depth 的近似，不是作者原始 `q_vec`。因此它是 PACS paper-style reconstruction 的重要阶段成果，但还不是完整全数据论文级 correction。

- 目前是 P56-only，不是完整 P0/P21/P56 correction。
- 使用 top detected peaks，不是全部 300,755 peaks。
- `cap_rates` 是基于 depth 的近似。
- 当前方法去除 batch-associated peaks，但没有在全数据中同时建模 age/developmental biology。
- UMAP 是随机且描述性的，需要配合定量指标判断。

## 11. 下一步计划

- 使用 10000/10000/FDR0.05 作为当前 P56 主结果。
- 保留 20000/10000/FDR0.05 作为稳定性检查。
- 不立即运行 20000/20000，除非有明确必要。
- 探索 cell-type-stratified PACS filtering。
- 比较 global batch peak removal 与 cell-type-specific batch peak removal。

6. 谨慎扩展到多年龄模型。
7. 检查被去除 batch peaks 的基因组位置、基因关联或 motif 富集。

## 12. AI 协作说明

本阶段大量使用 ChatGPT/Codex 进行路线规划、代码撰写、调试、报告整理和结果解释。本人负责研究方向选择、关键命令运行、结果核验、参数决策、科学解释和汇报组织。这是一个 human-AI collaborative reproduction workflow。

## 附录：主要文件

- results/mouse\_kidney\_figures/gse157079\_matrix\_alignment\_smoke\_test.md
- results/mouse\_kidney\_figures/gse157079\_all\_cells\_top\_peaks\_lsi\_umap/all\_cells\_top\_peaks\_lsi\_umap\_report.md
- results/mouse\_kidney\_figures/gse157079\_p56\_pacs\_batch\_filter\_umap\_p56\_top10000\_test10000\_fdr005/p56\_pacs\_batch\_filter\_umap\_report.md
- results/mouse\_kidney\_figures/gse157079\_p56\_pacs\_batch\_filter\_umap\_p56\_top10000\_test10000\_fdr005/p56\_batch\_mixing\_quantification\_report.md
- results/mouse\_kidney\_figures/gse157079\_p56\_pacs\_batch\_filter\_umap\_p56\_top20000\_test10000\_fdr005/p56\_pacs\_batch\_filter\_umap\_report.md
- results/mouse\_kidney\_figures/gse157079\_p56\_pacs\_batch\_filter\_umap\_p56\_top20000\_test10000\_fdr005/p56\_batch\_mixing\_quantification\_report.md