

PACS 复现项目阶段报告：GSE UMAP 重建与 P56 批次效应特征去除

日期：2026-06-07

当前定位：阶段性 reconstruction。

项目仓库：https://github.com/Woodson-04/PACS_reproducing

本报告总结 PACS Notebook 1 benchmark 复现、GSE157079 小鼠肾脏 snATAC 数据接入、原始稀疏矩阵 UMAP 重建，以及 P56 两个批次的 batch-effect peak filtering 结果。全部结论来自已有输出文件。

摘要与核心结果表

本阶段首先复现 PACS 作者 Notebook 1 real kidney data benchmark，PACS 主方法达到 Type I error = 0.04008、power = 0.83337，说明主统计检验 workflow 已基本复现。随后接入公开 GSE157079 mouse kidney snATAC 数据，确认 cell-by-peak 稀疏矩阵大小(cells x peaks)。基于原始矩阵完成 all-cell TF-IDF/LSI/UMAP 重建，并在 P56 发育时期子集中使用 PACS 检测 batch-effect peaks(top10000 setting)，PACS 过滤后umap作图，并使用三类混合指标(PCA-logNorm、LSI-space 与 UMAP-space)衡量批次效应，均显示过滤后 batch mixing 显著改善。

表 1. 项目当前核心结果概览。

模块	核心结果
Notebook 1 PACS benchmark	Type I error = 0.04008; power = 0.83337
GSE157079 matrix	28316 cells x 300755 peaks; 166121193 nonzero entries
all-cell UMAP	top 20000 peaks; retained nonzeros = 85801336
P56 subset	13526 cells; P56_batch1 = 7129; P56_batch2 = 6397
PACS filtering	tested peaks = 10000; significant batch peaks = 6305; retained peaks = 3695
PCA-logNorm PC1:30	normalized score: 0.0510 → 0.3097
LSI_2:30	normalized score: 0.0520 → 0.3343
UMAP-space	normalized score: 0.02649 → 0.65073

1. 复现目标与边界

本项目目标是进行 PACS 方法学复现，并在 GSE157079 小鼠肾脏 snATAC 数据上构建 PACS paper-style UMAP reconstruction。当前重点不是完整重建原始 dev-kidney-snATAC atlas，而是验证 PACS 是否能在真实 snATAC 数据中识别并过滤批次效应相关特征。

表 2. PACS 原文 Fig.3a-d 目标与当前复现边界。

项目	PACS 原文 Fig.3a-d 目标	当前复现状态
数据	mouse kidney snATAC	GSE157079 public files
分析对象	batch-effect feature filtering 前后 UMAP	P56 two-batch subset
特征范围	作者设定的 feature universe	top10000 tested peaks
batch 检验	控制生物学协变量后检测 batch effect	full: ~ cell_type + batch ; null: ~ cell_type
图像定位	Fig.3a-d	Fig.3a-d author-style reconstruction

当前边界包括：只使用P56数据处理，为对其他发育时期细胞处理；top10000 peaks有一定稳定性，但毕竟和作者的不一样

2. Notebook 1 Benchmark：统计检验与复现结果

2.1 PACS 检验的统计检验逻辑

对 feature g 与 cell i ，设 Y_{gi} 为 accessibility observation， q_i 为 cell-specific depth/capture-related factor， X_i 为协变量。

Null 与 full model 可抽象表示为：

$$\begin{aligned} M_{0,g} : Y_g &\sim \text{depth/capture correction} + \text{covariates} \\ M_{1,g} : Y_g &\sim \text{depth/capture correction} + \text{covariates} + \text{tested factor} \end{aligned}$$

对应假设为：

$$H_0 : \beta_{g, \text{tested factor}} = 0$$

每个 feature 输出 p-value p_g ，并通过 Benjamini-Hochberg procedure 得到 $\text{FDR}_g = \text{BH}(p_g)$ 。benchmark 指标为：

$$\widehat{\text{T1E}} = \frac{\#\{g \in H_0 : p_g \leq \alpha\}}{\#\{g \in H_0\}}$$
$$\widehat{\text{Power}} = \frac{\#\{g \in H_1 : p_g \leq \alpha\}}{\#\{g \in H_1\}}$$
$$\overline{\text{T1E}} = \frac{1}{R} \sum_{r=1}^R \widehat{\text{T1E}}_r, \quad \overline{\text{Power}} = \frac{1}{R} \sum_{r=1}^R \widehat{\text{Power}}_r$$

表 3. Notebook 1 benchmark 中不同方法的 Type I error 与 power。

Metric	PACS / our	Seurat	ArchR	snapATAC	Fisher
Type I error	0.04008	0.06342	0.04096	0.01810	0.02208
Power	0.83337	0.82344	0.67437	0.76094	0.76630
Description	PACS main method	clean-room baseline	clean-room approximation	clean-room edgeR-style baseline	binary Fisher exact test




图 1. Notebook 1 benchmark 中不同方法的 Type I error 与 power。




图 2. permutation/null setting 下 PACS p-value 的 QQ plot。

QQ plot 解读。 permuted-label setting 对应 Type I error 检验。PACS p-value 在零假设下整体接近理论均匀分布，说明主方法的假阳性控制处于合理范围。该图与 Type I error = 0.04008 共同支持 Notebook 1 主 workflow 的统计校准。

PACS 主方法的 Type I error 接近 0.05，power 与作者 notebook 结果接近。由于作者原始 baseline helper 文件不可用，baseline 结果为 clean-room reimplemented comparisons。

3. GSE157079 数据接入与矩阵对齐

GSE157079 public files 包含 metadata、precomputed UMAP coordinates、peak list 与 cell-by-peak MatrixMarket sparse matrix。

表 4. GSE157079 矩阵、metadata 与 peak list 对齐结果。

Cells	Peaks	Nonzero entries	Metadata rows	Peak list rows	Matrix orientation
28316	300755	166121193	28316	300755	cell x peak

metadata 标准字段包括 row_index、cell_barcode、sample、cell_type、umap_1 与 umap_2。其中 row_index 用于合并 metadata 与 GEO UMAP coordinates。

表 5. GSE157079 各 sample 的细胞数量。

P56_batch1	P56_batch2	P0_batch1	P0_batch2	P21_batch1
7129	6397	5993	5436	3361

4. 从原始矩阵重建 All-Cell Top-Peak UMAP：数学原理与实现

本节在不依赖 GEO 预计算 UMAP 坐标的情况下，直接从 GSE157079 原始 MatrixMarket cell-by-peak 稀疏矩阵出发，完成 feature selection、TF-IDF、LSI 与 UMAP 的重建流程。需要强调的是，本节使用的是全体细胞和 detection count 最高的 20,000 个 peaks，不是 all-features UMAP。

设原始稀疏 cell-by-peak 矩阵为 $X \in \mathbb{R}^{n \times p}$ ，其中 $n = 28316$ 表示细胞数， $p = 300755$ 表示 peak 数。由于完整 all-feature 矩阵规模较大，跑all-features我的linux虚拟机内存和存储不够，本阶段先根据 peak detection count 选择前 $K = 20000$ 个 peaks，得到子矩阵 $X^{(K)} \in \mathbb{R}^{n \times K}$ 。因此，以下降维分析非全部 300755 个 peaks。

对细胞 i 和 peak j ，首先计算 term frequency:

$$TF_{ij} = \frac{X_{ij}}{\sum_l X_{il}}$$

其中分母表示细胞 i 在所选 peaks 上的总 accessibility counts。随后定义 peak j 的检测 frequency:

$$df_j = \sum_i \mathbf{1}(X_{ij} > 0)$$

并据此计算 inverse document frequency:

$$IDF_j = \log \left(1 + \frac{n}{df_j} \right)$$

TF-IDF 转换后的矩阵记为:

$$Z_{ij} = TF_{ij} IDF_j$$

实际计算中进一步进行 log scaling:

$$Z'_{ij} = \log(1 + cZ_{ij})$$

其中 c 为缩放常数。随后对 Z' 进行截断奇异值分解，得到 LSI 低维表示:

$$Z' \approx U_r \Sigma_r V_r^T, \quad L = U_r \Sigma_r$$

本阶段取 $r = 50$ ，并使用 $LSI_2 : LSI_{30}$ 作为 UMAP 输入。排除 LSI_1 的原因在后文 LSI-depth QC 中进一步验证：在本数据中， LSI_1 与细胞测序深度高度相关，因此更适合作为 depth/QC 相关轴，而不作为主要 batch mixing 评价空间。

UMAP 在 LSI space 中构建近邻图，并优化二维布局 $Y \in \mathbb{R}^{n \times 2}$ ，使低维空间中的邻域关系尽量保持高维 LSI 空间中的局部结构。

表 6. All-cell top-peak UMAP 的矩阵规模与降维设置。

Cells	Selected top peaks	Retained nonzeros	Sparse matrix dimension	LSI dimension	UMAP input
28316	20000	85801336	28316×20000	28316×50	LSI_2:LSI_30

GSE157079 all-cell top-peak LSI UMAP by sample




图 3a. 从原始 cell-by-peak 矩阵重建的 all-cell top-peak UMAP，按 sample 着色。

GSE157079 all-cell top-peak LSI UMAP by cell type




图 3b. 同一 embedding 按 cell type 着色，显示主要细胞类型结构。

该 all-cell top-peak UMAP 显示出 sample-associated structure，同时保留明显的 cell-type structure。该结果的作用是提供全细胞层面的参考图，这为后续选取P56作为batch效应消除对象提供直观原因参考。

再次说明，这一结果不等同于 PACS 过滤前的 P56 before UMAP。我的Fig.3论文图复现是在后续 P56 子集上分别基于 top 10,000 peaks 和 PACS-retained peaks重新计算得到的 embedding。

完整使用全部 300,755 个 peaks 的 all-features UMAP已尝试运行，但在完整读取 166,121,193 个非零坐标后，于 sparse Matrix 构建阶段被系统终止，推测主要原因是内存压力。因此，当前报告将本节结果表述为all-cell top-peak matrix-derived UMAP，而不将其称为 all-features UMAP。

5. P56 子集与 PACS Batch-Effect Peak Filtering

选择 P56 subset 的原因是 P56 具有两个 batch，且两组细胞数量均较充足，可在同一年龄背景下检测批次效应相关特征，避免将 P0/P21/P56 的发育差异误解为技术 batch effect。

表 7. P56 子集的 batch 与 cell-type 概况。

P56 cells	P56_batch1	P56_batch2	Cell types
13526	7129	6397	15

$$M_{0,g} : Y_g \sim \text{cell_type}$$

$$M_{1,g} : Y_g \sim \text{cell_type} + \text{batch}$$

在 R formula 中对应 formula_null = ~ cell_type 与 formula_full = ~ cell_type + batch。控制 cell_type 的目的是避免将细胞类型组成差异误判为 batch effect。

表 8. P56 PACS batch-effect peak filtering 的主设置与输出矩阵。

n_top_peaks	Tested peaks	Significant batch peaks	Retained peaks	FDR cutoff	Before matrix	After matrix
10000	10000	6305	3695	0.05	13526 x 10000	13526 x 3695

由于公开 GSE157079 文件不包含作者 Notebook 1 中使用的 q_vec，本阶段 cap_rates 使用 depth-derived approximation。

6. Fig.3a–d Author-Style UMAP 四联图

下图为 P56 two-batch top10000 setting 下的 Fig.3a–d author-style reconstruction：




图 4. P56 子集 PACS filtering 前后 UMAP 四联图，分别按 batch 与 cell type 着色。

before by batch 显示 P56_batch1 与 P56_batch2 呈现明显 batch separation；after by batch 显示移除 PACS-significant batch peaks 后 batch separation 减弱。before / after by cell type 用于评估 cell-type structure 是否得到保留。UMAP aspect ratio 与 global shape 不固定，与作者图差异可

能来自 cell subset、feature universe、UMAP initialization/parameters 以及 plotting panel settings。

7. Normalized Batch Mixing Score: 数学定义

对 cell i ，设 batch label 为 b_i ， k -nearest neighbors 为 $N_k(i)$ 。cell-level score 为：

$$s_i = \frac{1}{k} \sum_{j \in N_k(i)} I(b_j \neq b_i)$$

observed score 为：

$$S_{\text{obs}} = \frac{1}{n} \sum_i s_i$$

设 m_{ab} 表示 cell type a 、batch b 下的 cell 数。给定细胞类型组成下的随机混合期望为：

$$S_{\text{exp}} = \frac{1}{n} \sum_a \sum_b m_{ab} \left(\frac{\sum_{d \neq b} m_{ad}}{\sum_d m_{ad}} \right)$$

normalized batch mixing score 为：

$$S_{\text{norm}} = \frac{S_{\text{obs}}}{S_{\text{exp}}}$$

S_{norm} 接近 0 表示强 batch separation；接近 1 表示在给定 cell-type composition 下接近随机混合。batch mixing 越高通常越好，但必须同时考虑 cell-type preservation。

8. 三层定量指标：PCA-logNorm、LSI 与 UMAP

为避免仅凭二维 UMAP 图形判断 PACS filtering 效果，本报告在三个不同坐标空间中计算 paper-style normalized batch mixing score。三类空间的作用不同：PCA-logNorm 最接近 PACS 原文中的 normalized PCA mixing；LSI_2:30 是适用于 scATAC-seq 稀疏 accessibility 矩阵的补充低维空间；UMAP-space 则仅作为 visualization-level 的辅助指标。

表 9. 三层定量指标的坐标空间、数学对象与用途。

指标层级	数学对象	解释	用途
PCA-logNorm	log-normalized peak matrix 的 PCA score	最接近 PACS paper normalized PCA mixing 的 author-like metric	主指标
LSI_2:30	TF-IDF 矩阵的 truncated SVD score	scATAC-aware low-dimensional representation	支持指标
UMAP-space	由高维邻域图优化得到的二维 embedding	visualization-level embedding	辅助指标

8.1 PCA-logNorm 空间

设过滤前或过滤后的 cell-by-peak count matrix 为 $X \in \mathbb{R}^{n \times p}$ 。首先对 accessibility counts 进行二值化，得到 $B_{ij} = \mathbf{1}(X_{ij} > 0)$ 。记第 i 个细胞的 library size 为 $d_i = \sum_j B_{ij}$ ，并以中位数深度 d_{med} 作为缩放基准，则 library-size normalized matrix 可写为：

$$\tilde{X}_{ij} = \frac{B_{ij}}{d_i} d_{\text{med}}$$

随后进行 log transformation：

$$X_{ij}^{\text{log}} = \log(1 + \tilde{X}_{ij})$$

对 X^{log} 进行 PCA，取前 q 个主成分作为坐标空间：

$$X^{\text{log}} \approx T_q P_q^T, \quad C^{\text{PCA}} = T_q$$

其中 $C^{\text{PCA}} \in \mathbb{R}^{n \times q}$ 表示细胞在 PCA-logNorm 空间中的坐标。本报告分别使用 $q = 20, 30, 50$ 计算 batch mixing score。

表 10. PCA-logNorm 空间中不同 PCA 维度下的 normalized batch mixing score。

PCA dimensions	before	after	fold change
PC1:20	0.0398	0.2576	6.48×
PC1:30	0.0510	0.3097	6.07×
PC1:50	0.0685	0.4239	6.19×

8.2 LSI 空间

LSI 空间来自 TF-IDF 矩阵的截断奇异值分解。设 TF-IDF 及 log scaling 后的矩阵为 Z' ，则：

$$Z' \approx U_r \Sigma_r V_r^\top, \quad C^{\text{LSI}} = U_r \Sigma_r$$

其中 $C^{\text{LSI}} \in \mathbb{R}^{n \times r}$ 表示细胞的 LSI 坐标。由于后文 QC 显示 LSI_1 与测序深度高度相关，本报告以 $LSI_2 : LSI_{30}$ 作为主要 LSI-space batch mixing 评价空间。

8.3 UMAP 空间

UMAP 以 PCA-logNorm 或 LSI 等高维坐标为输入，先构建细胞间的近邻图，再优化二维坐标 $C^{\text{UMAP}} \in \mathbb{R}^{n \times 2}$ ，使低维空间尽可能保留高维空间的局部邻域结构：

$$C^{\text{UMAP}} = \text{UMAP}(C^{\text{high}})$$

因此，UMAP-space score 反映的是二维可视化空间中的邻域混合情况。由于 UMAP 会重塑局部和全局几何结构，该指标只作为辅助说明，不作为最接近原文 normalized PCA mixing 的主指标。

8.4 三类空间中的共同 mixing score 计算

对任一坐标空间 C ，先在该空间中计算每个细胞 i 的 k -nearest neighbors，记为 $N_k(i)$ 。设细胞 i 的 batch label 为 b_i ，则细胞层面的 observed batch mixing score 为：

$$s_i(C) = \frac{1}{k} \sum_{j \in N_k(i)} \mathbf{1}(b_j \neq b_i)$$

数据层面的 observed score 为：

$$S_{\text{obs}}(C) = \frac{1}{n} \sum_{i=1}^n s_i(C)$$

为控制 cell type composition 的影响，设 $M = (m_{ab})$ 为 cell type-by-batch 计数矩阵，其中 m_{ab} 表示 cell type a 、batch b 中的细胞数。给定 cell type 组成下，无 batch effect 时的期望不同 batch 邻居比例为：

$$S_{\text{exp}} = \frac{1}{n} \sum_a \sum_b m_{ab} \left(\frac{\sum_{d \neq b} m_{ad}}{\sum_d m_{ad}} \right)$$

最终 normalized batch mixing score 定义为：

$$S_{\text{norm}}(C) = \frac{S_{\text{obs}}(C)}{S_{\text{exp}}}$$

该指标越接近 1，表示在给定 cell type composition 后越接近随机 batch mixing；越接近 0，则表示 batch separation 越强。需要注意，batch mixing score 的提高应与 cell-type preservation 指标共同解释，避免将真实生物学结构也一并消除。

表 11. PCA-logNorm、LSI 与 UMAP 空间中的 normalized batch mixing score 汇总。

坐标空间	before	after	解释
PCA-logNorm PC1:30	0.0510	0.3097	最接近原文 normalized PCA mixing 的主结果
PCA-logNorm PC1:50	0.0685	0.4239	PCA 维度敏感性结果
LSI_2:30	0.0520	0.3343	scATAC-aware supporting metric
UMAP-space	0.02649	0.65073	visualization-level auxiliary metric




图 5. PCA-logNorm、LSI 与 UMAP 空间中的 normalized batch mixing score 对比。三类坐标空间均显示 PACS filtering 后 batch mixing 明显改善。

三类坐标空间均显示 after-filtering score 高于 before-filtering score。其中 PCA-logNorm 是最接近 PACS 原文 normalized PCA mixing 的主指标；LSI_2:30 是适合 scATAC-seq 稀疏矩阵的支持指标；UMAP-space 则用于说明二维可视化空间中的 邻域混合变化。因此，PACS filtering 的效果不只是 UMAP visualization artifact，而是在 PCA-like 和 LSI 等高维表示空间中也得到支持。

9. LSI_1-Depth QC 与维度敏感性

在 scATAC-seq 的 TF-IDF/LSI 分析中，第一维 LSI component 常常与细胞测序深度或 global accessibility 强相关。由于本报告需要在 LSI space 中计算 batch mixing score，因此有必要先检验 LSI_1 是否主要反映 depth/QC 轴。

表 12. LSI_1 与细胞 depth 的相关性 QC。

阶段	component	Spearman(depth)	Pearson(depth)
before	LSI_1	-0.9983	-0.9739
after	LSI_1	0.9976	0.9830




图 6. LSI components 与细胞 depth 的相关性。过滤前后 LSI_1 均与 depth 高度相关，因此在 LSI-space batch mixing score 中排除 LSI_1 具有明确的 QC 依据。

结果显示，过滤前 LSI_1 与 depth 的 Spearman 相关系数为 -0.9983 ，过滤后为 0.9976 ，绝对值均接近 1。这说明 LSI_1 几乎完全由 depth/QC 相关信号主导。因此，本报告采用 $LSI_2 : LSI_{30}$ 作为主要 LSI-space mixing score 的计算空间，以降低测序深度轴对 batch mixing 评价的影响。

表 13. 不同 LSI 维度选择下的 normalized batch mixing score 敏感性分析。

LSI 维度	before	after	improvement	说明
LSI_1:30	0.0576	0.2803	+0.2227	包含 depth-dominated LSI_1 ，仍显示改善
LSI_2:30	0.0520	0.3343	+0.2823	主 LSI 指标；排除 LSI_1
LSI_2:50	0.0793	0.3730	+0.2937	更多 LSI 维度下结论保持一致
LSI_1:50	0.0766	0.3088	+0.2322	包含 LSI_1 后改善幅度较低

维度敏感性分析显示，无论是否包含 LSI_1 ，以及使用 30 维还是 50 维，PACS filtering 后的 normalized batch mixing score 均高于过滤前，说明 batch mixing 改善并不依赖某一个特定的 LSI 维度选择。与此同时，排除 LSI_1 后的 $LSI_2 : 30$ 与 $LSI_2 : 50$ 均给出更高的 improvement，分别为 $+0.2823$ 和 $+0.2937$ ，高于包含 LSI_1 的 $LSI_1 : 30$ 与 $LSI_1 : 50$ 。这与前述 depth correlation QC 一致： LSI_1 主要反映测序深度相关变化，纳入该维度会削弱 LSI-space mixing score 对 batch correction 效果的解释性。因此，后续主报告采用 $LSI_2 : LSI_{30}$ 作为 scATAC-aware supporting metric。

10. GEO UMAP Reference 与 PCA-logNorm 参数稳定性

本节用于补充说明两类参考信息。首先，GEO precomputed UMAP 只能作为 public atlas/reference embedding 在 UMAP-space 中进行比较，因为 GEO 文件提供的是二维 UMAP 坐标，而不是 PCA 或 LSI 坐标。其次，为了使参数稳定性分析更接近 PACS 原文中的 normalized PCA mixing，本节使用本项目重新计算的 PCA-logNorm space mixing score 比较不同 PACS 参数设置。

10.1 GEO precomputed UMAP 的 UMAP-space reference

GEO precomputed UMAP 可能包含 atlas-level preprocessing、integration 或 correction steps，因此不应解释为 PACS-filtered ground truth。由于 GEO 公开文件只提供 UMAP 坐标，这里仅在 UMAP-space 中计算 normalized batch mixing score，用作可视化空间参考。

表 14. GEO precomputed UMAP 与 P56 PACS UMAP 的 UMAP-space reference score。

setting	coordinate space	normalized score	解释
P56 10000/10000 before	UMAP-space	0.02649	PACS filtering 前的二维 UMAP 邻域混合程度
P56 10000/10000 after	UMAP-space	0.65073	PACS filtering 后的二维 UMAP 邻域混合程度
GEO P56 precomputed UMAP	UMAP-space	0.93903	公开 atlas/reference embedding；不是 PACS-filtered ground truth

在 UMAP-space 中，GEO P56 precomputed UMAP 的 normalized score 为 0.93903，高于本项目 P56 PACS-filtered UMAP 的 0.65073。这说明 GEO 预计算 embedding 的 batch mixing 程度更高，但该结果可能反映了原 atlas-level processing 的综合作用。因此，GEO UMAP 适合作为公开参考坐标，而不能作为 PACS feature-filtering 的直接标准答案。

10.2 PCA-logNorm space 参数稳定性

为避免只依赖二维 UMAP 可视化指标，本项目进一步在 PCA-logNorm space 中比较不同 PACS 参数设置下的 paper-style normalized batch mixing score。该分析使用已有的 sparse count matrix、retained peak indices 与 metadata，不重新运行 PACS。由于该指标在 PCA-like space 中计算，因此比 UMAP-space 辅助指标更接近 PACS 原文中的 normalized PCA mixing。

表 15. PCA-logNorm space 中不同 PACS 参数设置的 normalized batch mixing score。

setting	top peaks	tested peaks	significant peaks	retained peaks	PC1:30 before	PC1:30 after	PC1:50 before	PC1:50 after
5000 tested	10000	5000	3140	1860	0.0510	0.3679	0.0685	0.5032
10000 tested	10000	10000	6305	3695	0.0510	0.3097	0.0685	0.4239
20000 top / 10000 tested	20000	10000	6208	3792	0.0398	0.2928	0.0556	0.4097




图 9. 不同 PACS 参数设置下的 PCA-logNorm paper-style normalized batch mixing score。三组设置均显示 filtering 后 score 明显升高，说明 batch mixing 改善并不依赖单一参数选择。

PCA-logNorm 参数稳定性分析显示，三组设置在 PC1:30 和 PC1:50 中均表现出稳定的 before-to-after improvement。该结果说明，PACS filtering 对 batch mixing 的改善不仅存在于 UMAP 可视化空间中，也存在于更接近原文 normalized PCA mixing 的 PCA-logNorm space 中。

需要注意的是，after score 最高并不必然代表该参数设置最优。5000 tested peaks 设置在 PCA-logNorm space 中 after score 最高，但仅保留 1860 个 peaks，过滤更激进，可能更容易损失 biological accessibility features。10000 tested peaks 设置保留 3695 个 peaks，并且此前在 cell-type preservation 指标中表现更平衡；20000 top / 10000 tested 设置与 10000 tested peaks 设置结果接近，可作为扩大 feature universe 后的 稳定性验证。因此，综合 batch mixing improvement、retained feature number 与 cell-type structure preservation，本报告仍以 10000 top / 10000 tested / FDR 0.05 作为当前主展示设置。

综上，GEO precomputed UMAP 仅作为 UMAP-space reference；参数稳定性分析则以 PCA-logNorm space 为主。二者回答的问题不同：前者说明公开 atlas embedding 的可视化混合程度，后者检验本项目 PACS feature-filtering workflow 在 PCA-like space 中的稳定性。

11. 当前复现亮点

- PACS Notebook 1 主方法复现成功，Type I error 与 power 均处于合理范围。
- GSE157079 原始稀疏矩阵、metadata 与 peak list 已完成对齐验证。
- 已从原始 cell-by-peak matrix 出发重建 all-cell TF-IDF/LSI/UMAP。
- P56 two-batch setting 中完成 cell-type-adjusted PACS batch-effect peak detection。
- P56 before/after UMAP 四联图形成 Fig.3a–d author-style reconstruction。
- PCA-logNorm、LSI-space 与 UMAP-space 三层定量指标均支持 PACS filtering 改善 batch mixing。
- LSI_1-depth QC 为使用 LSI_2:30 提供明确依据。

12. 局限性

表 16. 当前复现工作的主要局限性。

局限性	含义	对结论的影响
P56-only two-batch subset	未覆盖 P0/P21/P56 全部细胞	结论限于 P56 batch filtering
top10000 peaks	未测试全部 300755 peaks	当前为 top-peak proof of concept
depth-derived cap_rates	缺少作者原始 q_vec	可能影响 PACS p-value calibration
PCA-logNorm implementation	可能不同于作者内部 PCA preprocessing	不直接比较作者数值
GEO UMAP reference	public atlas/reference embedding	不作为 PACS ground truth
baseline helper missing	Notebook 1 baseline 为 clean-room 实现	不声称完整复现 baseline
Fig.3e/f 未完成	尚未做 motif/gene-level extension	当前报告聚焦 Fig.3a–d

13. 下一步计划

A. 继续完善 Fig.3a–d

- 审阅当前报告与图注。
- 补充 figure copy 与 PDF 渲染。
- 统一 UMAP panel size、legend 与字体。
- 在不改变主结果的前提下，补充更清晰的 parameter comparison visualization。

B. 推进 Fig.3e/f

- 根据作者图内容确定是否涉及 DAR-linked genes、motif enrichment 或 gene activity。
- 整理 peak annotation 与 motif database。
- 在 P56 PACS-filtered peak set 基础上做 downstream enrichment。
- 明确哪些部分可由当前公开数据支持，哪些需要额外 annotation 或作者参数。

附录 A：核心文件索引

- results/current_important_results_summary.md
- results/20260526_2318_large_baseline/summary.csv
- results/mouse_kidney_figures/gse157079_matrix_alignment_smoke_test.md
- results/mouse_kidney_figures/gse157079_all_cells_top_peaks_lsi_umap/all_cells_top_peaks_lsi_umap_report.md

- `results/mouse_kidney_figures/gse157079_p56_pacs_batch_filter_umap_p56_top10000_test10000_fdr005_lsi_saved/p56_pacs_batch_filter_umap_p56_top10000_test10000_fdr005_lsi_saved_report.md`
- `results/mouse_kidney_figures/paper_style_batch_mixing_score_pca_space/p56_10000_pca_space_score_report.md`
- `results/mouse_kidney_figures/paper_style_batch_mixing_score_lsi_space/p56_paper_style_metric_final_interpretation.md`
- `results/mouse_kidney_figures/paper_style_batch_mixing_score_lsi_space/p56_lsi_depth_correlation_report.md`
- `results/mouse_kidney_figures/geo_precomputed_umap_quantification/geo_precomputed_umap_quantification_report.md`

附录 B：AI 协作说明

本项目中 AI 协作主要用于阅读和整理已有脚本、结果表与报告，根据作者 notebook 逻辑辅助修复 PACS workflow，生成 GSE157079 数据接入、matrix-derived UMAP、P56 PACS filtering 与 batch mixing quantification 的阶段总结。本报告中的数值均来自项目已有输出文件。